A股因子挖掘研究报告

全市场 2017-2026 · 行为价量 + 价值基本面 · 中性化构造 · 2026样本外

更新日期 2026-07-21 · 仓库 alphas-exploration

摘要

本项目在本地 tushare 全A面板（2017-2026）上，以【检索→生成→评估→蒸馏】的轮次循环挖掘选股因子。因子分属若干独立【集】，各自拥有登记簿、经验记忆、逐轮报告与评估产物。核心发现如下：

1. 2026样本外是显著衰减而非干净反转。 复合信号2026日频rank IC仍弱正（行为全量+0.065、规范价量+0.057、复合+0.025），但远低于历史约0.10；组合回测因样本小（约10次调仓）+极端分位而反转亏损。

2. 规模+行业中性化是免费的最高价值改造。 它在2026把多空损失近乎腰斩（行为全量多空 -20.8%→-10.0%），历史零成本，日频IC反而升高；证明2026失败大部分是风格暴露而非核心信号。

3. 成本约束在复合层面而非单因子层面生效。 单因子中位数扣15bp换手成本后 -1.6%（70%不可交易），但复合组合净超额 +5.1%/年。因此换手/成本感知打分为【上报】而非硬门槛。

4. 2026逐因子筛选：隔夜跳空持续是最稳健且可交易的alpha。
329个因子中111个仍有效、29个同时高效；冠军为隔夜跳空持续 TsMed(OPEN/Delay(CLOSE,1)-1)。此结论直接印证了 GTJA-191 复现中【A股价量优势本质是隔夜效应】的判断。

5. 精选集 robust_2026 与 20日价值套件 value_20d。 前者为跨期稳健且可交易的非隔夜因子精选（历史超额+10.2%/年 IR1.74）；后者验证价值在20日远强于10日，是与行为组合正交的真实分散来源，但2026处于价值不利区间。

一、方法与评估框架

入口 code/mining/round.py。候选文件定义 CANDIDATES=[{name, expr, family, rationale, logic_score}] 与可选 SET_NAME/FIELD_WHITELIST，经 data.py（宽表面板）、operators.py（算子沙箱）、pipeline.py（四阶段门）、alphaseval.py（指标）、registry.py、memory.py 流转。

标签 fwd_ret_10d（t+1 vwap入场，停牌安全）；全A tradable_entry掩码；日频Spearman rank IC。窗口：样本内 2017-2021；样本外门 2022-2023；持有 2024-2025（已耗尽）；2026 为全新样本外。

评估门	阈值
S1 快速IC	|IS IC|>=0.03, |ICIR|>=0.30, 覆盖>=0.60
S2 集合相关	|corr|<0.70 vs 现有集；1.3倍IC替换豁免
S3 轮内去重	|corr|>=0.70 保留最优
S4 稳健性（6子测）	OOS同号；3子域2/3；年度同号率>=0.60；滚动120/20>=0.70；分块自助p<=0.05；分位单调>=0.60
构造（2026-07新增）	GATE_ON_NEUTRALIZED：S1/S4对规模+行业中性化后的残差打分

2026-07的三项改造沉淀于 code/mining/construct.py（中性化/复合/可投掩码的单一真源）：① 中性化默认构造 ② S4分位单调门 ③ 状态型可投过滤（弃用微盘规模剔除）。

二、三个因子集

集	因子数	词表	说明
behavioral_full	112	全词表	OHLCV+换手+振幅+涨跌停+资金流+北向+两融+估值+行业
canonical	105	仅OHLCV/VWAP/AMOUNT/RET	AST强制；与behavioral_full高度重叠
canonical_composite	119	规范因子的秩积复合	cxalpha_；2026成本脆弱

behavioral_full 与 canonical 截面秩相关高达0.96（见元复合），基本冗余。behavioral_full 为主部署集。

三、2026样本外检验：显著衰减，而非干净反转

抓取全新2026数据（8个日频端点，约128天），扩展面板并在真正未见的2026窗口回测各集EW复合。更正后的诚实结论：复合日频rank IC在2026保持弱正（+0.065/+0.057/+0.025 vs 历史约0.10），即约腰斩式衰减；分位/组合回测（仅约10次非重叠调仓）反转亏损是小样本+极端分位假象。此前所称【反转】言过其实。

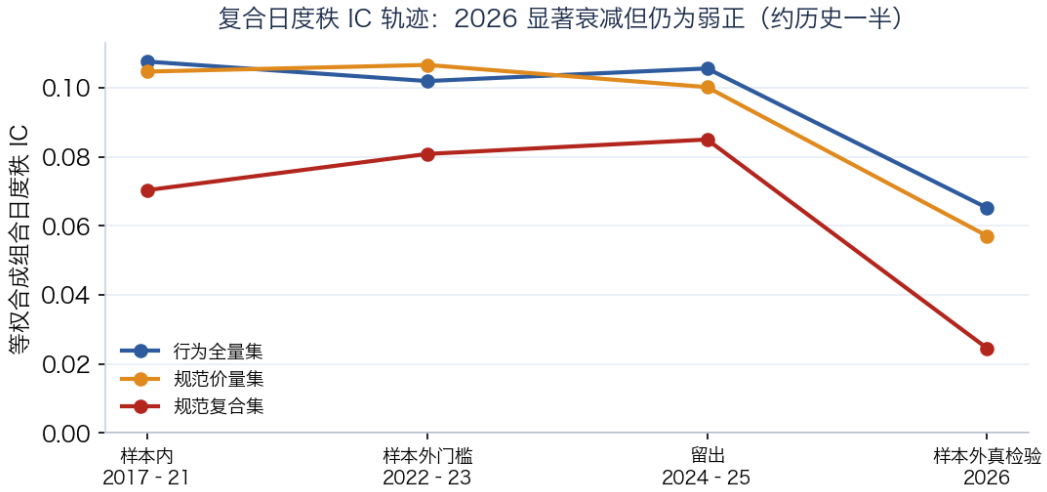


图1 复合信号历史vs各窗口IC（若存在）。

四、规模+行业中性化

对复合信号逐日在【行业哑变量 + log流通市值】上取残差（Barra-lite）。四变体（原始/筛选/中性化/筛选+中性化）在历史与2026对比：

集 (中性化)	历史超额	历史IC	2026超额	2026多空	2026 IC
behavioral_full	+8.0%	0.105	-2.7%	-10.0%	0.073
canonical	+6.1%	0.102	-7.5%	-23.3%	0.067
canonical_composite	+5.6%	0.076	-15.6%	-41.4%	0.033

中性化把2026多空损失近乎腰斩，历史零成本，日频IC反升（例 +0.065→+0.073）：2026失败大部分是风格暴露。而生硬微盘剔除反而有害（edge部分存在于小盘）。详见 results/mining/NEUTRALIZE_REPORT.md。

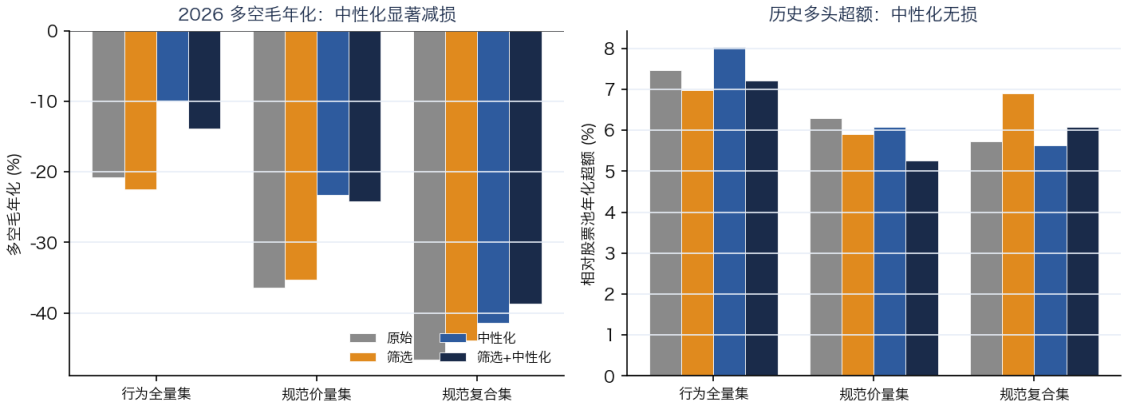


图2 中性化 vs 微盘筛选：2026多空与历史超额对比。

五、换手/成本感知打分

每个因子登记其分位换手与扣15/30bp成本后的多头超额。关键：成本约束在复合层面生效，而非单因子。

层级	毛超额	净@15bp	分位换手
单因子（behavioral_full中位）	+3.7%	-1.6%	0.65
复合（behavioral_full）	+9.0%	+5.1%	0.48

单因子net>0门会误杀70%语料；复合通过分散既升毛超额又降换手，净由负转强正。故 GATE_ON_NET_COST 默认关闭，cost_aware_score 用于【偏好】低换手候选。详见 results/mining/COST_ANALYSIS.md。

六、滚动IC衰减监测

对中性化生产信号跟踪120日移动rank IC，相对样本内基线分级 健康(>=0.60x)/观察(0.30-0.60x)/受损/破裂。

集	基线IC	2025末移动IC	状态	2026 IC	2026状态
behavioral_full	0.105	0.087 (0.83x)	健康	0.073 (0.70x)	健康
canonical	0.100	0.075 (0.75x)	健康	0.067 (0.67x)	健康
canonical_composite	0.069	0.066 (0.97x)	健康	0.033 (0.47x)	观察

中性化信号2017-2025无长期衰减（行为全量年度IC 0.089-0.115）；2026为首个低于基线之年但未破裂。信号历史上曾进入观察区（2020疫情、2022-23熊市）并复原，故属【降低信心】而非退出。

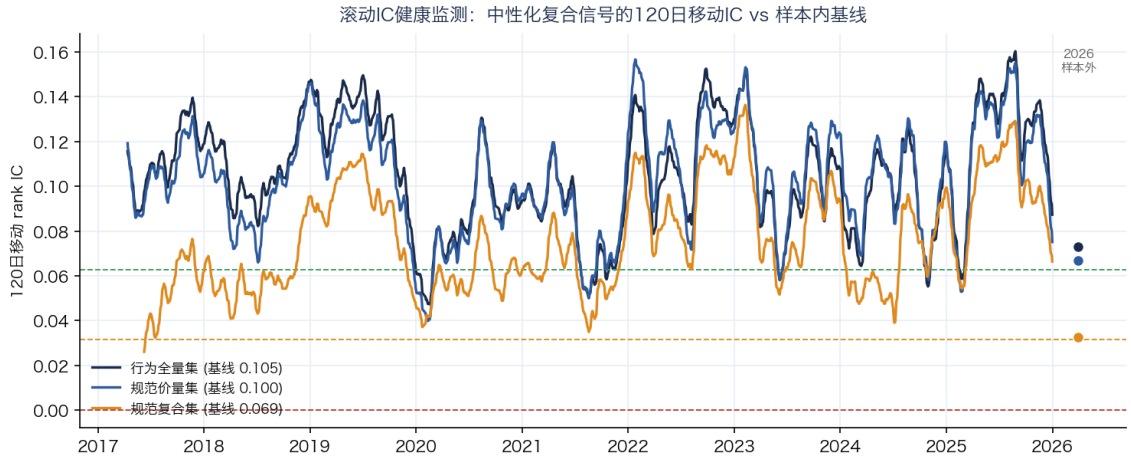


图3 滚动IC健康监测：三集中性化复合的120日移动IC vs 基线。

七、跨集元复合（负面结果）

三集基于不同词表，本应部分正交。实测：behavioral_full~canonical
截面秩相关0.962、IC序列相关0.98；等权/IR加权元复合（历史超额+7.5%、2026 -10.5%）劣于单独behavioral_full（+8.0%、-2.7%）。

教训：混合同一底层行为的价量词表毫无增益--真正的分散必须来自不同数据族（价值/基本面），见第十一节。

八、2026逐因子筛选：哪些alpha有效且高效

对全部329因子按表达式在2017-2026重算，在2026窗口打分：有效=方向化IC同号且>=0.03；高效=扣自身15bp换手成本后多头超额>0。

	数量
有效（2026仍预测）	111 (34%)
高效（净成本后可交易）	34 (10%)
有效且高效	29 → 24个独立信号

冠军是隔夜跳空持续：TsMed(OPEN/Delay(CLOSE,1)-1,20) 净+46.6%/年，前十有四个是同一隔夜信号--直接印证GTJA-191 复现【A股价量优势本质是隔夜效应】。其余稳健低换手脉络：事件稀有（【安静】股跑赢）与大单资金流背离。有效性常见，高效性才是约束：高换手的非对称/彩票族多被成本吞噬。

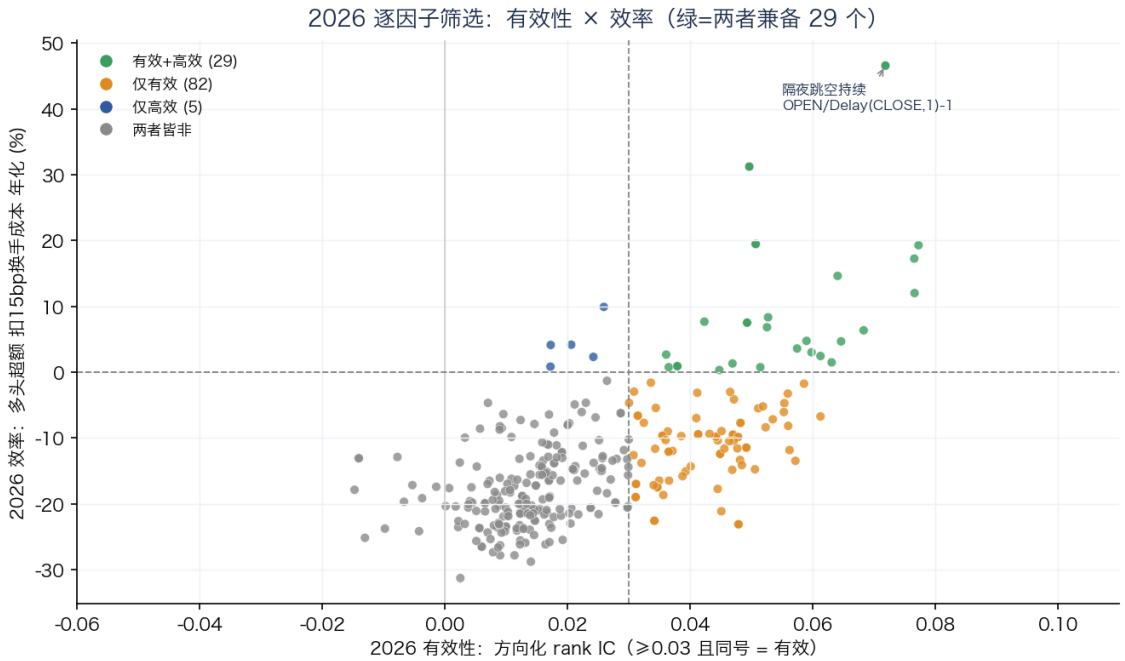


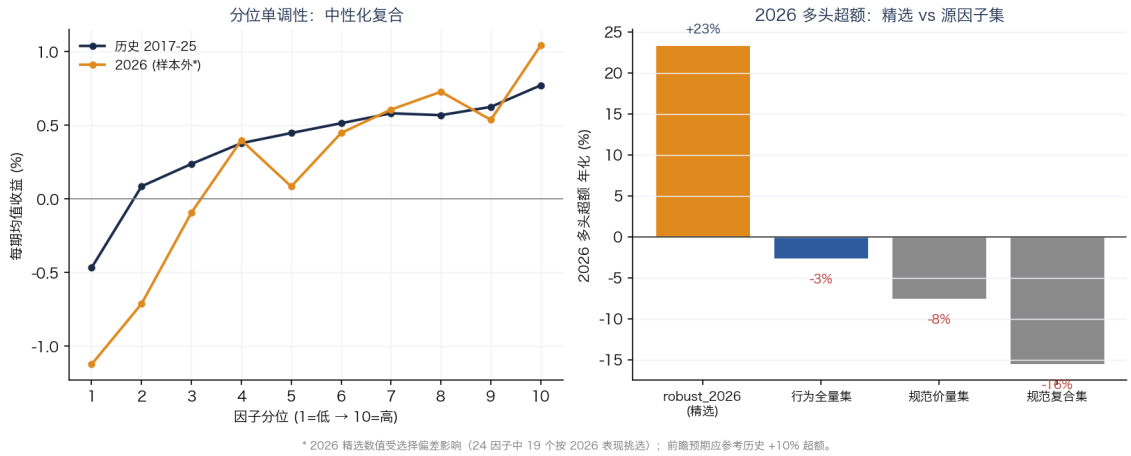
图4 2026逐因子筛选：有效性(方向化IC) × 效率(扣成本净超额)。绿=两者兼备29个。

九、精选集 robust_2026 及回测

按用户选择构建的非隔夜、跨期稳健且可交易精选集（25个 ralpha_）：5个新挖(R13-14) + 19个过往有效高效(排除隔夜) + 1个(R1-2)。中性化EW复合回测：

窗口	超额/IR	多头净@15bp(IR)	多空毛Sharpe
全期 2017-25	+10.2% / 1.74	+14.2% / 0.62	2.58
样本内	+11.7% / 2.12	+11.4% / 0.56	3.45
OOS 2022-23	+11.3% / 1.67	+4.4% / 0.17	1.79
2026 中性化	+23.4%	多空 +69.2% / IC 0.111	-

诚实警示（选择偏差）：2026的+23.4%被高估--24因子中19个是用2026数据挑选的（2026 IC 0.111 反超历史0.081即是铁证）。唯一干净的样本外是5个新挖因子（仅用2017-25定门）。前瞻预期应参考历史约+10%超额并对衰减打折，而非选择膨胀的+23%。



* 2026 精选数值受选择偏差影响（24 因子中 19 个按 2026 表现挑选）；前瞻预期应参考历史 +10% 超额。

图5 robust_2026：分位单调(历史vs2026) 及 2026多头超额 vs 源因子集。

十、新挖掘轮次（避开隔夜脉络）

R13-14（behavioral_full）：从事件稀有、稳健中位、耦合等非隔夜脉络挖掘。R13 8/27录用，R14 4/19录用。在2026再筛选，2个跨期稳健且高效：

因子	脉络	IS IC	2026 IC	2026净@15bp
alpha_0144 -TsCount(TURN_F>2均,120)	换手尖峰稀有(安静注意)	+0.047	+0.071	+15.4%
alpha_0146 TsMed(AMOUNT,60)/TsMean	成交额中位/均值比	+0.042	+0.057	+8.3%

教训：中位/均值比值（有界、低换手）可交易，而均值-中位差虽有效却被换手吞噬--【有效≠可交易】。robust_2026 自挖R1-2共33候选仅留1个（ralpha_0026
峰值相对成交量）：精选集因构造已近最优，其低换手脉络立即S2锁死。

十一、20日价值套件 value_20d

专设20日价值/基本面套件（valpha_；全仓库唯一以 fwd_ret_20d 设门）。机制：候选文件在加载时置 cfg.HORIZON=20（round.py先runpy候选文件再读HORIZON，各轮独立进程），不污染10日各集。

因子	IS IC	OOS IC	2026 IC	角度
valpha_0001 CsRank(EP)*CsRank(CFP)	+0.052	+0.024	+0.023	价值一致(盈利+现金流)
valpha_0002 CsRank(SP)+CsRank(Delta(SP,120))	+0.044	+0.069	-0.013	便宜+销售成长
valpha_0003 CsRank(EP)-CsRank(Log(CMV))	+0.029	+0.067	-0.007	便宜+小盘
valpha_0004 CsRank(EP)-CsRank(TsSum(RET,20))	+0.078	+0.057	+0.006	逆向价值

价值在20日远强于10日（IS/OOS 0.024-0.078 vs 约0.03），且与行为组合正交（S2相关约0）=真实分散来源。但四者在2026H1均弱转负（价值不利区间；2026@20d仅约4次调仓/85天=短窗，非否决，价值有周期性）。价值×行为交互在20日同样失败。

十二、结论与后续

结论：①中性化是最高价值免费改造，应作默认构造；②成本约束在复合层生效；③隔夜跳空持续是最稳健可交易的价量alpha；④价值在20日是真实正交分散源但当前区间不利；⑤精选集近最优，再挖同一价量域收益递减。

后续（未请求）：value_20d 在20日的EW复合回测；行为(10d)+价值(20d)混合套件的全历史风险调整检验；复合层换手削减（缓冲带）；围绕隔夜脉络的专门轮次（若放开避开约束）。

所有构造/评估产物见 results/mining/：NEUTRALIZE_REPORT、COST_ANALYSIS、IC_MONITOR、META_COMPOSITE、VALID_2026、各集 BACKTEST 与逐轮 round_NN.md；图见 results/mining/figs/。